Análise Temporal de Shelf Life

Ranking de Importância de Ensaios Físico-Químicos

por Random Forest e XGBoost

Versões: Com Limites e Sem Limites

Relatório Técnico

27 de março de 2026

Sumário

1 Introdução **5**

2 Metodologia **6**

2.1 Visão Geral 6
2.2 Variáveis Temporais Criadas 6
2.3 Estrutura das Entradas do Modelo 7
2.4 Versão com Limites 8
2.4.1 Regras de Inclusão por Família 8
2.4.2 Regras de Inclusão por Ensaio 8
2.4.3 Descritores Utilizados 8
2.4.4 Ajuste do Modelo 8
2.4.5 Agregação das Importâncias 9
2.5 Versão Sem Limites 9
2.6 Diferença Conceitual entre as Versões 9
2.7 Motivos de Exclusão de Famílias 10
2.8 Avaliação do Desempenho Preditivo 10
2.8.1 Papel das Métricas nesta Análise 10
2.8.2 Métricas de Ajuste — Random Forest 11
2.8.3 Métricas de Ajuste — XGBoost 11
2.8.4 Interpretação dos Resultados 12

3 Resultados — Versão com Limites **14**

3.1 Random Forest — Versão com Limites 14
3.1.1 Cenário Acelerado 14
3.1.2 Cenário de Longa Duração 15
3.1.3 Cenário de Acompanhamento 17
3.1.4 Síntese Geral — RF com Limites 19
3.2 XGBoost — Versão com Limites 19
3.2.1 Cenário de Longa Duração 19
3.2.2 Cenário Acelerado 20

3.2.3 Cenário de Acompanhamento 21
3.2.4 Síntese Geral — XGBoost com Limites 22
3.3 Comparativo RF vs. XGBoost — Versão com Limites 22

4 Resultados — Versão Sem Limites 23
4.1 Random Forest — Versão Sem Limites 23
4.1.1 Cenário de Longa Duração 23
4.1.2 Cenário Acelerado 24
4.1.3 Cenário de Acompanhamento 24
4.1.4 Famílias Excluídas — RF Sem Limites 24
4.1.5 Síntese Geral — RF Sem Limites 26
4.2 XGBoost — Versão Sem Limites 26
4.2.1 Cenário de Longa Duração 26
4.2.2 Cenário Acelerado 26
4.2.3 Cenário de Acompanhamento 27
4.2.4 Síntese Geral — XGBoost Sem Limites 27

5 Análise Sem Ensaios de Água 29
5.1 Motivação e Ensaios Excluídos 29
5.2 Resultados — Versão com Limites 29
5.2.1 Random Forest — Com Limites, Sem Ensaios de Água 30
5.2.2 XGBoost — Com Limites, Sem Ensaios de Água 33
5.3 Resultados — Versão Sem Limites 35
5.3.1 Random Forest — Sem Limites, Sem Ensaios de Água 35
5.3.2 XGBoost — Sem Limites, Sem Ensaios de Água 38
5.4 Impacto da Exclusão da Água: Comparativo com a Análise Principal . 40
5.5 Síntese Geral — Análise Sem Ensaios de Água 42

6 Conclusão 43
6.1 Achados Transversais 43
6.2 Padrão dos Descritores Temporais 43
6.3 Comparação entre Modelos e Versões 44
6.4 Recomendações 44

Lista de Figuras

3.1 Importância relativa de features por família — Cenário Acelerado (RF vs. XGBoost, versão com limites). 15
3.2 Ranking detalhado de features por família — Cenário Acelerado. 15
3.3 Importância relativa de features por família — Cenário de Longa Duração (RF vs. XGBoost, versão com limites). 17
3.4 Ranking detalhado de features por família — Cenário de Longa Duração. 17
3.5 Importância relativa de features por família — Cenário de Acompanhamento (RF vs. XGBoost, versão com limites). 18
3.6 Ranking detalhado de features por família — Cenário de Acompanhamento. 19
3.7 Heatmap de diferença de importância entre RF e XGBoost (RF − XGBoost). Valores positivos (azul) indicam maior peso atribuído pelo RF; valores negativos (vermelho) indicam maior peso pelo XGBoost. 22

Lista de Tabelas

2.1 Descritores temporais utilizados nos modelos. 7
2.2 Comparação entre as versões com e sem limites. 9
2.3 Métricas de ajuste in-sample — Random Forest (com e sem limites). . 11
2.4 Métricas de ajuste in-sample — XGBoost (com e sem limites). 12

4.1 Famílias excluídas da análise RF sem limites, por motivo e cenário. . . 25

5.1 Ranking RF com limites, sem ensaios de água — todos os cenários. . . 32
5.2 Ranking XGBoost com limites, sem ensaios de água — todos os cenários. 34
5.3 Ranking RF sem limites, sem ensaios de água — famílias com maior confiabilidade ($\geq$ 4 produtos). 37
5.4 Ranking XGBoost sem limites, sem ensaios de água — famílias com maior confiabilidade ($\geq$ 4 produtos). 39
5.5 Impacto da exclusão dos ensaios de água por família — versão RF com limites. 41

6.1 Resumo comparativo entre modelos e versões. 44

Capítulo 1

Introdução

Este relatório apresenta os resultados da análise temporal de *Shelf Life* realizada sobre três bases de dados distintas - cenários de **longa duração**, **acelerado** e **acompanhamento** - utilizando dois algoritmos de aprendizado de máquina: **Random Forest** e **XGBoost**.

O objetivo central foi identificar, dentro de cada família de produtos, quais ensaios físico-químicos apresentam maior associação com o *Shelf Life*, tratado como variável-alvo contínua. Para isso, o histórico temporal de cada ensaio foi convertido em descritores resumidos, e modelos de regressão foram ajustados separadamente por família de produtos.

O relatório está organizado da seguinte forma:

- **Capítulo 2** descreve a metodologia completa, incluindo a construção das variáveis temporais, as regras de inclusão, os dois algoritmos utilizados e a avaliação do desempenho preditivo in-sample;
- **Capítulo 3** apresenta os resultados da versão com limites, mais conservadora e interpretável;
- **Capítulo 4** apresenta os resultados da versão sem limites, com cobertura máxima e caráter mais exploratório;
- **Capítulo 5** apresenta uma análise de sensibilidade com a exclusão dos ensaios relacionados à água, revelando os ensaios substitutos em cada família;
- **Capítulo 6** sintetiza os achados gerais.

Capítulo 2

Metodologia

2.1 Visão Geral

A análise foi conduzida a partir de três bases processadas, correspondentes aos cenários de longa duração, acelerado e acompanhamento. Em todas as versões, o objetivo foi identificar, dentro de cada família de produtos, quais ensaios físico-químicos apresentavam maior associação com o *Shelf Life*, tratado como variável-alvo contínua.

A lógica central consistiu em transformar o histórico temporal de cada ensaio em um conjunto de **descritores resumidos**, de forma que o modelo não utilizasse diretamente as observações brutas ao longo do tempo, mas sim medidas sintéticas que capturam o comportamento temporal de cada ensaio. Assim, o eixo do tempo entrou no modelo de forma indireta, por meio de variáveis derivadas da trajetória de cada ensaio.

Em ambas as versões, a modelagem foi feita **separadamente por família de produtos**. Não foi treinado um único modelo global para todas as famílias. Para cada família, os produtos foram selecionados, suas variáveis temporais organizadas em formato tabular, e então foi ajustado um modelo específico para explicar o *Shelf Life* naquele subconjunto.

2.2 Variáveis Temporais Criadas

As análises temporais se basearam em descritores construídos a partir da sequência de valores de cada ensaio ao longo de dias. A ideia foi resumir o comportamento do ensaio no tempo em variáveis numéricas mais informativas para o modelo.

Tabela 2.1: Descritores temporais utilizados nos modelos.

Descritor	Definição
`slope`	Inclinação da reta ajustada aos pontos do ensaio ao longo do tempo. Representa a tendência temporal. Positivo = aumento; negativo = queda; próximo de zero = pouca tendência linear.
`abs_slope`	Valor absoluto de `slope`. Capta a intensidade da mudança ao longo do tempo, independentemente da direção.
`delta_total`	Diferença entre o último e o primeiro valor observado: $\Delta = x_{\text{final}} - x_{\text{inicial}}$. Resume a mudança acumulada total.
`margin0_norm`	Margem inicial normalizada até o limite de especificação. Quando existem limite mínimo e máximo: $\frac{\min(\lvert x_0 - L_{\min}\rvert, \lvert L_{\max} - x_0\rvert)}{L_{\max} - L_{\min}}$. Com limite unilateral, usa-se a distância absoluta.
`min_margin_norm`	Menor margem observada ao longo de toda a série temporal. Captura o momento de maior aproximação aos limites de especificação durante o estudo.
`oos_any`	Variável binária: 0 = nunca saiu de especificação; 1 = saiu em pelo menos um momento.
`first_oos_day`	Primeiro dia em que o ensaio saiu de especificação. Ausente quando o ensaio nunca saiu da faixa.

2.3 Estrutura das Entradas do Modelo

O modelo não recebeu diretamente a tabela bruta em formato longo. Em vez disso, os dados foram reorganizados de modo que cada linha da matriz de entrada correspondesse a um produto, e cada coluna a um ensaio combinado com um descritor temporal. Por exemplo:

- `Água, %p__slope`
- `Água, %p__abs_slope`
- `Água, %p__delta_total`
- `Índice de acidez__slope`
- `Índice de acidez__delta_total`

- ...

A variável-alvo y foi sempre o *Shelf Life* do produto.

2.4 Versão com Limites

A versão com limites foi a versão mais conservadora e robusta da análise, desenhada para evitar rankings obtidos em famílias ou ensaios com suporte muito pequeno.

2.4.1 Regras de Inclusão por Família

Uma família só era modelada quando atendia simultaneamente às condições:

- possuir pelo menos 5 produtos;
- apresentar variação em *Shelf Life* dentro da família.

Se todos os produtos da família tivessem o mesmo *Shelf Life*, ela era excluída, pois o modelo não teria variação no alvo para aprender.

2.4.2 Regras de Inclusão por Ensaio

Dentro de cada família, cada ensaio precisava aparecer em pelo menos:

$$\max(2,\ \lceil 0{,}40 \times n_{\text{produtos}} \rceil)$$

produtos, ou seja, em 40% dos produtos da família, respeitando um mínimo absoluto de 2 produtos.

2.4.3 Descritores Utilizados

Na versão com limites, os descritores usados como entrada do modelo foram: `slope`, `abs_slope`, `delta_total`, `margin0_norm`, `min_margin_norm`, `oos_any` e `first_oos_day`.

2.4.4 Ajuste do Modelo

Para cada família, foi treinado o modelo com:

- `n_estimators = 200`
- `random_state = 42 + seed`
- O modelo foi repetido 12 vezes (variando a semente) para reduzir dependência de um único ajuste.
- A importância final foi a média entre as 12 repetições.

2.4.5 Agregação das Importâncias

As importâncias de todos os descritores pertencentes ao mesmo ensaio foram somadas, gerando o ranking principal por ensaio. Adicionalmente, foi identificado, para cada ensaio, o **descritor dominante** — aquele que concentrou a maior parcela da importância agregada.

2.5 Versão Sem Limites

A versão sem limites foi construída para oferecer **cobertura máxima**, reduzindo as exclusões por critérios conservadores. Foram removidos os filtros de mínimo de 5 produtos por família e de presença mínima de 40% por ensaio.

Mesmo assim, condições mínimas continuaram obrigatórias:

- pelo menos 2 produtos por família;
- variação em *Shelf Life*;
- pelo menos uma variável numérica utilizável após a montagem.

Na versão sem limites, o conjunto de descritores foi mais amplo, incluindo também `n_points`, `value0` e `value_last`.

2.6 Diferença Conceitual entre as Versões

Tabela 2.2: Comparação entre as versões com e sem limites.

Característica	Com Limites	Sem Limites
Mín. produtos por família	5	2
Mín. presença por ensaio	40%	Sem restrição
Descritores utilizados	7	10
Exibe descritor dominante	Sim	Não
Robustez interpretativa	Alta	Variável
Cobertura de famílias	Menor	Máxima

Atenção — Interpretação dos Resultados

A versão com limites é a mais apropriada para **conclusões sólidas**. A versão sem limites é a mais apropriada para mostrar **tudo o que foi possível calcular**, deixando claro o caráter mais exploratório de algumas famílias. Famílias com Peso 1 = 1,000 e demais pesos iguais a zero, especialmente em famílias com 2–3

produtos, não devem ser interpretadas como prova de dominância absoluta do ensaio.

2.7 Motivos de Exclusão de Famílias

As principais causas de exclusão de famílias do ranking são:

1. **Poucos produtos reais na família:** o script exige um número mínimo de produtos para que o resultado não fique frágil.
2. ***Shelf Life* sem variação:** se todos os produtos da família tiverem o mesmo *Shelf Life*, o modelo não tem o que aprender.
3. **Pouca presença de ensaio na família:** um ensaio precisa aparecer em fração mínima dos produtos.
4. **Valores numéricos ausentes ou inválidos:** se `Resultado_Numerico` estiver muito vazio ou não puder ser convertido corretamente.
5. **Poucas medições ao longo do tempo:** para calcular inclinação, delta e margens, é preciso histórico suficiente.
6. **Ensaios demais, mas muito esparsos:** após filtros, sobram poucas ou nenhuma coluna robusta.
7. **Limites matemáticos ausentes:** descritores como margem ao limite dependem de `Limite_Min` e `Limite_Max`.

2.8 Avaliação do Desempenho Preditivo

2.8.1 Papel das Métricas nesta Análise

O foco principal desta análise foi a **identificação dos ensaios físico-químicos mais associados ao *Shelf Life***, por meio da importância de variáveis extraída dos modelos. Não se tratou, portanto, de um problema de predição em sentido estrito: o objetivo não foi construir um modelo para prever o *Shelf Life* de novos produtos, mas sim utilizar modelos de aprendizado de máquina como instrumentos de **quantificação de associação** entre os descritores temporais dos ensaios e a variável-alvo.

Ainda assim, a avaliação do desempenho preditivo in-sample cumpre uma função metodológica importante: ela serve como **verificação de sanidade** dos rankings de importância obtidos. Importâncias extraídas de um modelo que não ajustou adequadamente aos dados refletem, em grande parte, ruído e não sinal real. Por isso, reportar

as métricas de ajuste à base é essencial para demonstrar que os modelos capturaram estrutura real nos dados antes de qualquer extração de importâncias.

É importante ressaltar que as métricas apresentadas nesta seção são de **desempenho in-sample** — calculadas sobre os mesmos dados utilizados no treinamento de cada modelo, dentro de cada família. Trata-se, portanto, de medidas de **ajuste à base**, e não de generalização para novos dados. A interpretação adequada dessas métricas é: o modelo conseguiu capturar a variação observada no *Shelf Life* dentro do conjunto disponível, o que legitima a extração de importâncias. Uma análise de validação cruzada, voltada à capacidade preditiva propriamente dita, constituiria uma etapa complementar e distinta desta análise.

2.8.2 Métricas de Ajuste — Random Forest

A Tabela 2.3 apresenta as métricas de ajuste in-sample agregadas por cenário para o modelo Random Forest, nas versões com e sem limites. Os valores de MAE e RMSE estão expressos na mesma unidade do *Shelf Life* (dias).

Tabela 2.3: Métricas de ajuste in-sample — Random Forest (com e sem limites).

Versão	Cenário	Famílias	Produtos	MAE	RMSE	R^2
Com limites	Longa duração	4	33	66,33	98,71	0,7482
	Acelerado	4	35	69,25	101,46	0,7214
	Acompanhamento	3	22	38,77	53,45	0,8583
	Geral	**11**	**90**	**60,73**	**90,96**	**0,7531**
Sem limites	Longa duração	12	57	63,78	88,15	0,7929
	Acelerado	13	63	62,99	86,99	0,7887
	Acompanhamento	8	35	95,91	158,74	0,7461
	Geral	**33**	**155**	**70,71**	**107,81**	**0,7751**

2.8.3 Métricas de Ajuste — XGBoost

A Tabela 2.4 apresenta as métricas correspondentes para o modelo XGBoost.

Tabela 2.4: Métricas de ajuste in-sample — XGBoost (com e sem limites).

Versão	Cenário	Famílias	Produtos	MAE	RMSE	R^2
Com limites	Longa duração	4	33	23,17	78,32	0,8415
	Acelerado	4	35	21,99	76,05	0,8435
	Acompanhamento	3	22	1,18	2,16	0,9998
	Geral	**11**	**90**	**17,34**	**67,08**	**0,8658**
Sem limites	Longa duração	12	57	13,90	59,61	0,9053
	Acelerado	13	63	12,70	56,71	0,9102
	Acompanhamento	8	35	32,79	130,90	0,8273
	Geral	**33**	**155**	**17,68**	**80,52**	**0,8746**

2.8.4 Interpretação dos Resultados

Em ambos os modelos e em todas as versões, os coeficientes de determinação (R^2) situaram-se em patamares que confirmam a capacidade dos modelos de capturar variação real no *Shelf Life*. Para o Random Forest, os valores agregados ficaram entre 0,72 e 0,86; para o XGBoost, entre 0,83 e 0,91, com exceção do cenário de acompanhamento com limites, que atingiu $R^2 = 0{,}9998$.

Esse valor extremamente elevado no XGBoost para o cenário de acompanhamento com limites — envolvendo apenas 3 famílias e 22 produtos — é consistente com o comportamento esperado desse algoritmo em conjuntos de dados pequenos: o XGBoost, por sua natureza de boosting sequencial, tende ao ajuste quase perfeito in-sample quando o número de amostras é reduzido. Esse resultado reforça a recomendação de utilizar as importâncias do XGBoost com cautela adicional em famílias pequenas, pois importâncias derivadas de um modelo com sobreajuste podem refletir particularidades do conjunto de treinamento e não padrões generalizáveis.

Para o Random Forest, os valores de R^2 na casa de 0,72–0,86 indicam ajuste sólido e equilibrado, coerente com a natureza mais regularizada desse algoritmo. O cenário de acompanhamento sem limites apresentou RMSE mais elevado (158,74 dias), em parte explicado pela inclusão de mais famílias heterogêneas — com diferentes escalas de *Shelf Life* — na versão sem limites.

De forma geral, os resultados confirmam que os modelos capturaram sinal interpretável nos dados, legitimando a extração e a análise das importâncias de variáveis reportadas nos capítulos seguintes.

Atenção — Interpretação dos Resultados

As métricas desta seção são de **desempenho in-sample** e não devem ser lidas como estimativas de capacidade preditiva para novos produtos. Sua função é confirmar que os modelos ajustaram com qualidade suficiente para que as importâncias de variáveis sejam informativas. Uma avaliação preditiva formal exigiria validação cruzada ou um conjunto de teste independente, o que constitui uma etapa complementar não realizada nesta análise.

Capítulo 3

Resultados — Versão com Limites

3.1 Random Forest — Versão com Limites

3.1.1 Cenário Acelerado

No cenário acelerado, os resultados indicaram que diferentes famílias químicas apresentaram padrões distintos de associação entre os ensaios físico-químicos e o *shelf life*.

Em **Other ethoxylate**, observou-se claro predomínio de **Água, %p**, com peso bastante superior aos demais ensaios. O principal descritor associado a esse ensaio foi a **margem inicial normalizada em relação ao limite** (`margin0_norm`), indicando que, nessa família, o *shelf life* parece estar fortemente relacionado à condição inicial do produto em relação à faixa de especificação. Em outras palavras, o fator mais informativo não foi necessariamente a velocidade de degradação, mas sim o quanto a variável já iniciava próxima ou distante do limite permitido. O **Índice de hidroxila** apareceu em segundo plano, com importância bem menor, sendo mais associado à intensidade de variação ao longo do tempo.

Na família **Blend - Crop**, a interpretação mostrou um comportamento mais multifatorial. Os dois ensaios com maior contribuição foram **Água, %p** e **Cor Gardner, 25ºC**, com pesos relativamente próximos, sugerindo que o *shelf life* não depende de um único marcador dominante, mas de pelo menos dois sinais relevantes. Para **Água, %p**, o descritor dominante foi a velocidade absoluta de mudança (`abs_slope`), enquanto para **Cor Gardner** predominou a menor margem normalizada ao limite (`min_margin_norm`). Esse padrão sugere que, para essa família, o *shelf life* está associado simultaneamente à dinâmica temporal da água e à aproximação crítica da cor aos limites de especificação. O **pH 1% p/p, aquoso, 25ºC** apareceu como variável complementar, com contribuição secundária.

Na família **Alkyl Ester**, os resultados foram particularmente consistentes do ponto de vista técnico. Os ensaios mais relevantes foram **Índice de acidez** e **Índice de saponificação**, com pesos bastante próximos, seguidos por **Cor Gardner** e, mais dis-

tante, **Água, %p**. Para o **Índice de acidez**, o descritor dominante foi o `delta_total`, indicando que a mudança acumulada entre o início e o fim da série temporal foi o principal sinal relacionado ao *shelf life*. Para o **Índice de saponificação** e para **Cor Gardner**, predominou a velocidade absoluta de mudança (`abs_slope`).

Por fim, em **Blend - E&R**, o resultado deve ser interpretado com cautela. Apenas um ensaio válido permaneceu após os filtros, e o peso observado foi praticamente nulo. Trata-se de um resultado exploratório, sem robustez suficiente para sustentar conclusões firmes.

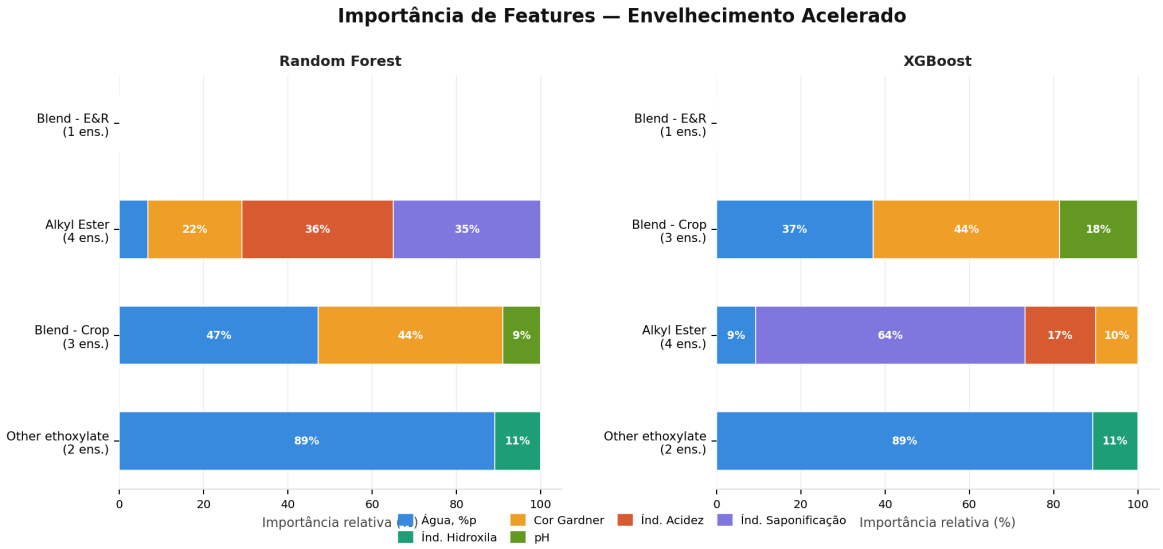

Figura 3.1: Importância relativa de features por família — Cenário Acelerado (RF vs. XGBoost, versão com limites).

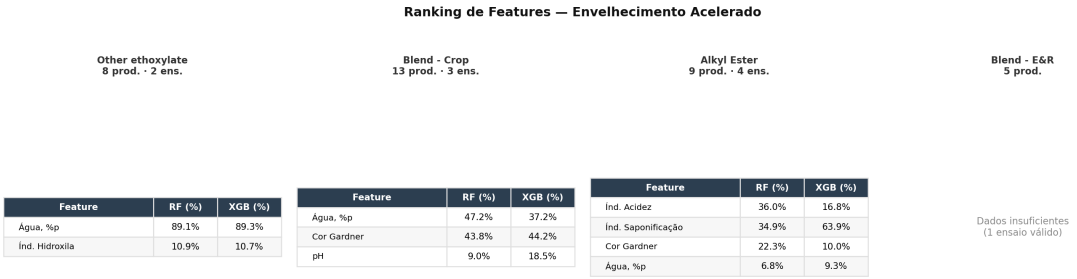

Feature	RF (%)	XGB (%)
Água, %p	89.1%	89.3%
Índ. Hidroxila	10.9%	10.7%

Feature	RF (%)	XGB (%)
Água, %p	47.2%	37.2%
Cor Gardner	43.8%	44.2%
pH	9.0%	18.5%

Feature	RF (%)	XGB (%)
Índ. Acidez	36.0%	16.8%
Índ. Saponificação	34.9%	63.9%
Cor Gardner	22.3%	10.0%
Água, %p	6.8%	9.3%

Figura 3.2: Ranking detalhado de features por família — Cenário Acelerado.

3.1.2 Cenário de Longa Duração

No cenário de longa duração, os resultados reforçaram alguns padrões observados no cenário acelerado, mas também evidenciaram mudanças importantes na forma como os ensaios se relacionam com o *shelf life* ao longo de um horizonte temporal mais extenso.

Em **Other ethoxylate**, o ensaio **Água, %p** voltou a se destacar como o principal fator explicativo, com ampla superioridade em relação aos demais. Entretanto, diferentemente do observado no cenário acelerado, o descritor dominante passou a ser a **inclinação temporal com sinal** (`slope`), indicando que, nessa condição, a tendência da água ao longo do tempo foi mais informativa do que a margem inicial até o limite. O segundo ensaio mais relevante foi **RSN, Número de água, mL**, associado principalmente à menor margem ao limite, sugerindo contribuição complementar ligada à proximidade crítica em relação à especificação.

Na família **Alkyl Ester**, o comportamento foi ainda mais claro do ponto de vista químico. O ensaio mais relevante foi o **Índice de saponificação**, seguido pelo **Índice de acidez**, com contribuições menores de **Água, %p** e **Cor Gardner**. O descritor dominante do **Índice de saponificação** foi a inclinação temporal (`slope`), sugerindo que a direção e a intensidade da mudança desse ensaio ao longo do tempo representam o principal sinal associado ao *shelf life* da família. Para o **Índice de acidez**, o principal descritor foi o `delta_total`, reforçando a importância da mudança acumulada ao longo do estudo. Esses resultados indicam que, em longa duração, o *shelf life* de **Alkyl Ester** parece ser fortemente governado por mecanismos de degradação química progressiva.

Em **Blend - Crop**, novamente observou-se um padrão bifatorial, com forte participação de **Água, %p** e **Cor Gardner, 25ºC**. Os pesos ficaram bastante próximos, evidenciando que o *shelf life* dessa família depende de mais de um eixo de variação. Para **Água, %p**, o descritor dominante foi o `delta_total`, indicando que a variação acumulada entre o início e o final do estudo teve papel central. Já para **Cor Gardner**, o descritor mais importante foi a menor margem ao limite (`min_margin_norm`), sugerindo que a cor se torna particularmente relevante quando se aproxima criticamente da especificação ao longo do tempo. O **pH** apareceu novamente como variável secundária.

Assim como no cenário acelerado, a família **Blend - E&R** apresentou resultado pouco robusto.

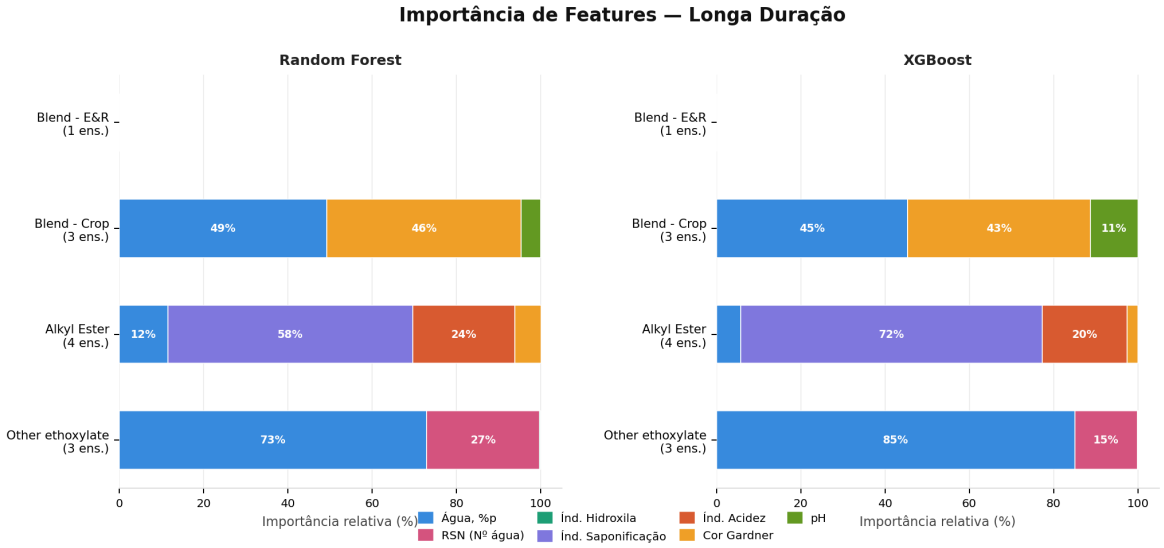

Figura 3.3: Importância relativa de features por família — Cenário de Longa Duração (RF vs. XGBoost, versão com limites).

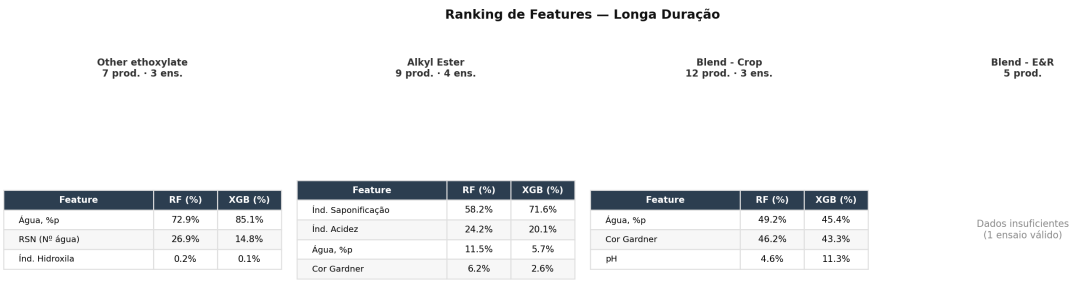

Feature	RF (%)	XGB (%)
Água, %p	72.9%	85.1%
RSN (Nº água)	26.9%	14.8%
Índ. Hidroxila	0.2%	0.1%

Feature	RF (%)	XGB (%)
Índ. Saponificação	58.2%	71.6%
Índ. Acidez	24.2%	20.1%
Água, %p	11.5%	5.7%
Cor Gardner	6.2%	2.6%

Feature	RF (%)	XGB (%)
Água, %p	49.2%	45.4%
Cor Gardner	46.2%	43.3%
pH	4.6%	11.3%

Figura 3.4: Ranking detalhado de features por família — Cenário de Longa Duração.

3.1.3 Cenário de Acompanhamento

No cenário de acompanhamento, os resultados mostraram um perfil mais distribuído entre diferentes ensaios, especialmente em famílias relacionadas a álcoois etoxilados.

Em **Ethoxylated natural alcohol**, o ensaio com maior importância foi o **Índice de hidroxila**, seguido pelo **Índice de acidez**, enquanto **Água, %p** e **pH** apareceram com relevância menor. O descritor dominante do **Índice de hidroxila** foi a menor margem normalizada ao limite (`min_margin_norm`), indicando que o fator mais informativo foi a aproximação crítica desse ensaio à especificação ao longo do estudo. Já para o **Índice de acidez**, predominou a inclinação temporal (`slope`), sugerindo que a tendência de evolução desse parâmetro também exerce influência importante sobre o *shelf life*. Esse conjunto de resultados indica que, nessa família, o *shelf life* parece estar

associado tanto à proximidade dos limites quanto à trajetória temporal de degradação química.

Na família **Ethoxylated synthetic alcohol**, o comportamento foi claramente multifatorial. O ensaio **Óxido de Eteno, ppm** apareceu em primeiro lugar, seguido de perto por **Índice de hidroxila** e **Índice de acidez**, enquanto **Água, %p** teve contribuição moderada. Para o **Óxido de Eteno**, o descritor dominante foi a inclinação temporal (`slope`), sugerindo que a direção da mudança ao longo do tempo é um dos principais fatores associados ao *shelf life*. No caso do **Índice de hidroxila**, o descritor dominante foi o `delta_total`. Assim, nessa família, o *shelf life* parece ser explicado por uma combinação de diferentes mecanismos de degradação, sem a presença de um único ensaio absolutamente dominante.

Em **Ethoxylated nonyl phenol**, observou-se um resultado equilibrado entre vários ensaios. **Cor Pt-Co, 25°C** apareceu em primeiro lugar, seguida por **Água, %p**, **Índice de hidroxila** e **Índice de acidez**, com pesos relativamente próximos entre si. Para **Cor Pt-Co**, o descritor dominante foi a velocidade absoluta de mudança (`abs_slope`), indicando que a intensidade da alteração de cor ao longo do tempo é um dos sinais mais associados ao *shelf life*. Para **Água, %p**, predominou o `delta_total`, enquanto o **Índice de hidroxila** se associou principalmente à menor margem ao limite e o **Índice de acidez** à inclinação temporal.

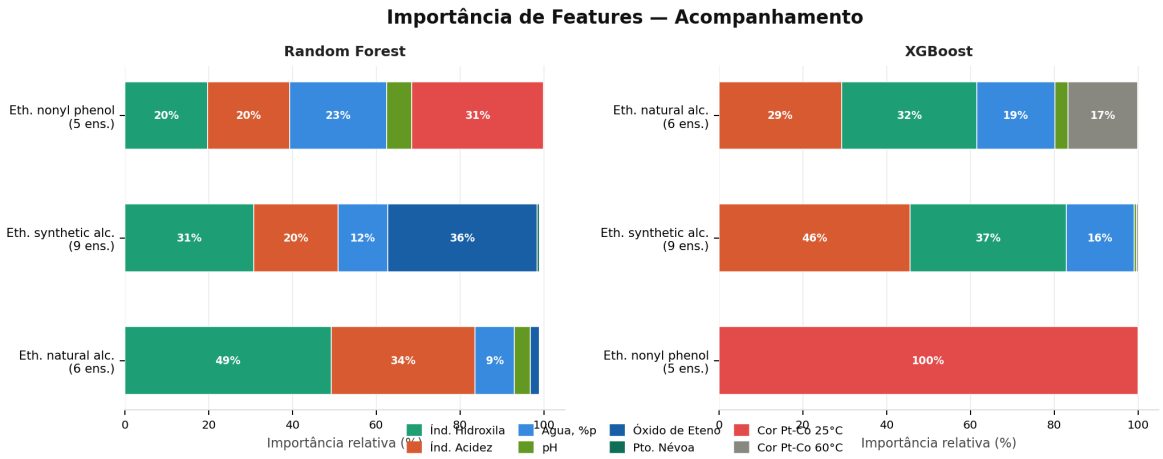

Figura 3.5: Importância relativa de features por família — Cenário de Acompanhamento (RF vs. XGBoost, versão com limites).

Ranking de Features — Acompanhamento

Eth. natural alc.
11 prod. · 6 ens.

Feature	RF (%)	XGB (%)
Índ. Hidroxila	49.3%	32.3%
Índ. Acidez	34.3%	29.3%
Água, %p	9.3%	18.6%
pH	3.8%	3.1%
Óxido de Eteno	2.2%	0.0%
Cor Pt-Co 60°C	0.0%	16.6%

Eth. synthetic alc.
5 prod. · 9 ens.

Feature	RF (%)	XGB (%)
Óxido de Eteno	35.6%	0.0%
Índ. Hidroxila	30.7%	37.3%
Índ. Acidez	20.2%	45.6%
Água, %p	11.9%	16.2%
Pto. Névoa	0.5%	0.0%
pH	0.0%	0.6%
Cor Pt-Co 60°C	0.0%	0.3%

Eth. nonyl phenol
6 prod. · 5 ens.

Feature	RF (%)	XGB (%)
Cor Pt-Co 25°C	31.4%	100.0%
Água, %p	23.2%	0.0%
Índ. Hidroxila	19.8%	0.0%
Índ. Acidez	19.5%	0.0%
pH	6.0%	0.0%

Figura 3.6: Ranking detalhado de features por família — Cenário de Acompanhamento.

3.1.4 Síntese Geral — RF com Limites

Síntese

Considerando conjuntamente os três cenários, observa-se que alguns ensaios aparecem de forma recorrente como relevantes para a explicação do *shelf life*: **Água, %p**, **Índice de hidroxila**, **Índice de acidez**, **Índice de saponificação** e variáveis associadas à **cor**. Em várias famílias, a importância não decorreu apenas da magnitude da variação ao longo do tempo, mas também da posição inicial do ensaio em relação ao limite ou da menor margem observada durante o estudo. Os resultados mostraram que algumas famílias são predominantemente explicadas por um único ensaio, como ocorreu em **Other ethoxylate**, enquanto outras apresentam comportamento claramente multifatorial, como **Blend - Crop**, **Ethoxylated synthetic alcohol** e **Ethoxylated nonyl phenol**. Em famílias como **Alkyl Ester**, os resultados sugeriram forte relação entre *shelf life* e parâmetros diretamente associados à degradação química. Por outro lado, alguns casos, como **Blend - E&R**, devem ser considerados exploratórios.

3.2 XGBoost — Versão com Limites

3.2.1 Cenário de Longa Duração

No cenário de longa duração, os resultados do XGBoost indicaram padrões relativamente bem definidos em algumas famílias, com concentração mais forte da importância em poucos ensaios.

Em **Other ethoxylate**, observou-se nítido predomínio de **Água, %p**, com peso muito superior aos demais ensaios. O descritor dominante foi `margin0_norm`, indicando

que, nessa família, o *shelf life* parece estar fortemente relacionado à posição inicial da água em relação ao limite de especificação. O segundo ensaio mais relevante foi **RSN, Número de água, mL**, associado principalmente a `delta_total`, enquanto o **Índice de hidroxila** teve contribuição praticamente residual.

Na família **Alkyl Ester**, o XGBoost apresentou um resultado tecnicamente bastante consistente. O ensaio mais importante foi o **Índice de saponificação**, seguido pelo **Índice de acidez**, ambos com descritor dominante `slope`. Isso indica que, para essa família, o *shelf life* parece estar mais associado à **tendência temporal desses parâmetros** do que apenas à sua posição inicial. **Água, %p** e **Cor Gardner, 25ºC** também apareceram, porém com pesos bem menores. Trata-se de um dos resultados mais fortes do cenário de longa duração, pois aponta para uma relação consistente entre *shelf life* e degradação química progressiva.

Na família **Blend - Crop**, o comportamento foi claramente multifatorial. Os dois ensaios mais relevantes foram **Água, %p** e **Cor Gardner, 25ºC**, com pesos muito próximos. No caso de **Água, %p**, o descritor dominante foi `abs_slope`, sugerindo que a intensidade da variação ao longo do tempo foi o principal sinal. Já para **Cor Gardner**, o descritor dominante foi `min_margin_norm`, indicando que a cor passou a ser particularmente importante quando se aproximou criticamente do limite de especificação ao longo do estudo.

Em **Blend - E&R**, o resultado não apresenta robustez interpretativa suficiente. Apenas um ensaio válido permaneceu após os filtros, e seu peso foi zero.

Atenção — Interpretação dos Resultados

Quando o XGBoost concentra fortemente a importância em uma variável, isso deve ser entendido como um forte indício de dominância dentro daquele conjunto de dados, e não necessariamente como prova de que os demais ensaios sejam irrelevantes na prática.

3.2.2 Cenário Acelerado

No cenário acelerado, o XGBoost manteve a tendência de concentrar a importância em poucos ensaios principais. Em **Other ethoxylate**, novamente houve forte predomínio de **Água, %p**, agora com descritor dominante `slope`, indicando que, no acelerado, o principal sinal associado ao *shelf life* foi a **tendência temporal da água**. O **Índice de hidroxila** apareceu como segundo ensaio, com descritor dominante `abs_slope`, mas com contribuição muito menor.

Na família **Alkyl Ester**, o ensaio mais importante continuou sendo o **Índice de saponificação**, mas o descritor dominante passou a ser `min_margin_norm`, o que representa uma diferença relevante em relação à longa duração. O **Índice de acidez**

continuou em segundo lugar, agora com descritor dominante `slope`, enquanto **Cor Gardner, 25ºC** e **Água, %p** apareceram em posições posteriores. A leitura global permanece coerente com a ideia de que, nessa família, o *shelf life* está ligado a processos de degradação química.

Na família **Blend - Crop**, o XGBoost apontou **Cor Gardner, 25ºC** como principal ensaio, ligeiramente à frente de **Água, %p**, enquanto **pH 1% p/p, aquoso, 25ºC** apareceu em terceiro lugar. O descritor dominante da cor foi `min_margin_norm`, sugerindo que o principal sinal foi a aproximação crítica da cor ao limite ao longo do estudo. Já para a água e para o pH, o descritor dominante foi `abs_slope`.

3.2.3 Cenário de Acompanhamento

No cenário de acompanhamento, o comportamento do XGBoost foi mais heterogêneo entre as famílias. Em **Ethoxylated nonyl phenol**, o modelo concentrou integralmente a importância em **Cor Pt-Co, 25ºC**, com peso igual a 1,000, enquanto todos os demais ensaios ficaram com peso zero. O descritor dominante foi `abs_slope`. Embora isso sugira um indício forte de que a cor tem papel central nessa família, esse resultado deve ser interpretado com cautela. O valor extremo de 1,000 não deve ser lido como prova de que apenas a cor importa, mas sim como indicação de que o XGBoost encontrou nessa variável um caminho dominante de separação dentro de uma família ainda relativamente pequena.

Na família **Ethoxylated synthetic alcohol**, os resultados ficaram mais distribuídos e interpretáveis. O ensaio mais importante foi o **Índice de acidez**, com descritor dominante `slope`, seguido pelo **Índice de hidroxila**, com descritor dominante `abs_slope`. Em terceiro lugar apareceu **Água, %p**, associada a `delta_total`. Esse padrão sugere que o *shelf life* está ligado principalmente à tendência temporal da acidez, à intensidade de variação da hidroxila e, em menor grau, à mudança acumulada da água.

Em **Ethoxylated natural alcohol**, o ensaio mais importante foi o **Índice de hidroxila**, cujo descritor dominante foi `min_margin_norm`. Em seguida vieram **Índice de acidez** e **Água, %p**, ambos associados a `slope`, e depois **Cor Pt-Co, 60ºC**, associada a `delta_total`. Esse conjunto sugere que o *shelf life* dessa família depende de uma combinação entre aproximação crítica da hidroxila ao limite, tendência temporal da acidez e da água e mudança acumulada da cor.

3.2.4 Síntese Geral — XGBoost com Limites

Síntese

Considerando os três cenários, o XGBoost com limites destacou repetidamente ensaios como **Água, %p**, **Índice de acidez**, **Índice de hidroxila**, **Índice de saponificação** e variáveis de **cor**. Os resultados mais convincentes foram observados em **Other ethoxylate**, **Alkyl Ester**, **Blend - Crop**, **Ethoxylated synthetic alcohol** e **Ethoxylated natural alcohol**, pois nessas famílias houve um padrão interpretável e coerente com a lógica química dos ensaios.

Já resultados como **Blend - E&R** (em ambos os cenários) e **Ethoxylated nonyl phenol** no acompanhamento devem ser apresentados com maior cautela: no primeiro caso, porque faltou base interpretável; no segundo, porque a concentração extrema do peso em uma única variável pode refletir mais a estrutura do modelo do que uma exclusividade real do ensaio na prática.

3.3 Comparativo RF vs. XGBoost — Versão com Limites

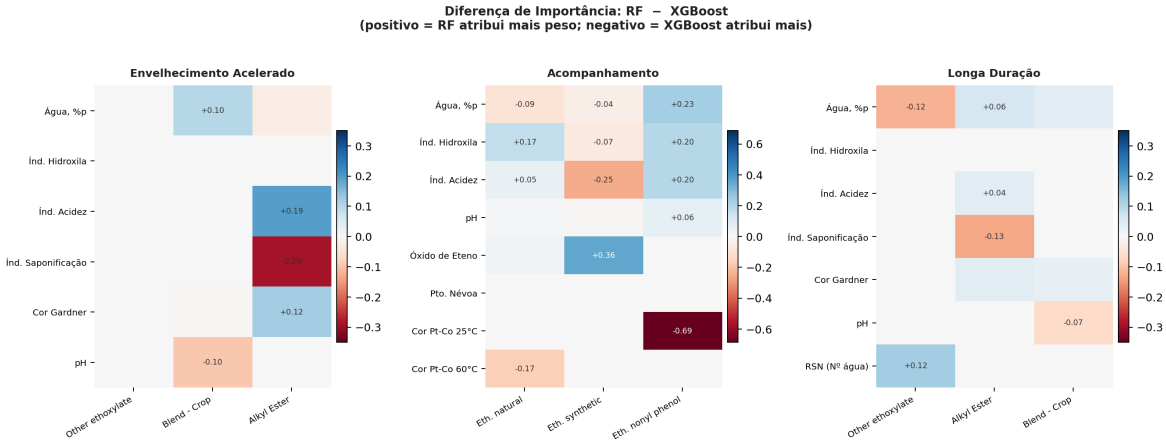

Figura 3.7: Heatmap de diferença de importância entre RF e XGBoost (RF − XGBoost). Valores positivos (azul) indicam maior peso atribuído pelo RF; valores negativos (vermelho) indicam maior peso pelo XGBoost.

De forma geral, RF e XGBoost apresentaram boa concordância nas famílias com maior número de produtos e distribuição menos extrema dos pesos. As principais divergências ocorreram em casos onde o XGBoost concentrou a importância em uma única variável, ao passo que o RF distribuiu de forma mais equilibrada entre os ensaios — o que é esperado dado o comportamento distinto dos dois algoritmos.

Capítulo 4

Resultados — Versão Sem Limites

Atenção — Interpretação dos Resultados

Na versão sem limites, a principal mudança foi o aumento da cobertura analítica. Isso é útil porque permite mostrar praticamente tudo o que foi matematicamente possível calcular. No entanto, essa ampliação traz um custo interpretativo importante: vários resultados passam a ter caráter mais **exploratório** do que confirmatório, especialmente nas famílias com apenas dois, três ou quatro produtos. Pesos extremos (Peso 1 = 1,000 e demais zerados) não devem ser lidos como prova de dominância absoluta.

4.1 Random Forest — Versão Sem Limites

4.1.1 Cenário de Longa Duração

Alguns resultados continuaram bastante coerentes e tecnicamente úteis. A família **Other ethoxylate** apresentou um padrão relativamente consistente, com forte predominância de **Água, %p** e participação secundária de **RSN, Número de água, mL**. A família **Alkyl Ester** se destacou como uma das mais interpretáveis, com maior relevância de **Índice de saponificação**, seguida por **Índice de acidez**, **Água, %p** e **Cor Gardner**. **EOPO copolymer** mostrou um perfil dominado por variáveis de **pH** e **Água**, enquanto **Alkylether Sulfate** teve maior concentração em **Insulfatados**, **Cloreto de sódio** e **Sulfato de sódio**. A família **Blend - Crop** apresentou um padrão mais distribuído, com destaque para **Água, %p**, **pH**, **Sólidos**, **Ácido fosfórico livre** e **Índice de aminas totais**.

A cautela é indispensável em algumas famílias. **Blend - HPC** (3 produtos) e **Blend - E&R** (5 produtos) exibiram Peso 1 = 1,000 para **Água, %p** e todos os demais pesos iguais a zero. Situação parecida ocorre em famílias com apenas dois produtos, como **Phosphate ester**, em que o ranking existe e pode servir como pista

exploratória, mas a robustez estatística é limitada.

4.1.2 Cenário Acelerado

A retirada dos limites aumentou de forma importante o número de famílias disponíveis para leitura. Algumas mantiveram padrão tecnicamente convincente. **Other ethoxylate** voltou a mostrar forte predominância de **Água, %p**, seguida por **Índice de hidroxila** e **RSN**. **Alkylether Sulfate** apresentou perfil concentrado em **Insulfatados**, **Cloreto de sódio** e **Sulfato de sódio**. **Blend - Crop** seguiu com comportamento mais multifatorial, liderado por **Água, %p**, mas com contribuição relevante de **pH**, **Índice de aminas totais**, **Ácido fosfórico livre** e **Sólidos**. **Alkyl Ester** continuou coerente, com **Índice de acidez**, **Índice de saponificação** e **Cor Gardner** formando o núcleo interpretativo principal.

No entanto, famílias como **Blend - E&R** e **Blend - HPC** voltaram a aparecer com Peso 1 = 1,000 para **Água, %p**, mas com número muito reduzido de produtos.

4.1.3 Cenário de Acompanhamento

A versão sem limites trouxe uma combinação interessante de famílias novas e famílias que já pareciam interpretáveis na versão mais rigorosa. **Ethoxylated synthetic alcohol** apresentou um padrão relativamente estável, com **Óxido de Eteno**, **Índice de hidroxila**, **Água, %p** e **Índice de acidez** formando o conjunto principal de variáveis. **Ethoxylated natural alcohol** destacou **Índice de hidroxila**, **Índice de acidez** e **Água**. **Ethoxylated nonyl phenol** exibiu distribuição relativamente equilibrada entre **Cor Pt-Co**, **Índice de acidez**, **Índice de hidroxila**, **Água** e **pH**.

Os casos que mais exigem cautela são **Alcohol** (2 produtos, Peso 1 = 1,000 para **Etanol, %p**), **Blend - Coatings** (3 produtos, Peso 1 = 1,000 para **Água, %p**) e **Blend - E&R** (todos os pesos iguais a zero, sem ranking interpretativamente útil).

4.1.4 Famílias Excluídas — RF Sem Limites

Mesmo na versão sem limites, ainda houve famílias excluídas por motivos estruturais:

Tabela 4.1: Famílias excluídas da análise RF sem limites, por motivo e cenário.

Família	**Cenário**	**Motivo**
Alcohol, Alkanolamine, Alkyl Sulfonate, Amidoamine, Betaine, Break Fluid, Eth. Tallow amine, Eth. triestyryl phenol, Eth. coconut amine, Fatty acid, Glycol, Natural fatty alcohol	Longa duração	Menos de 2 produtos
Alkyl sulfate, Amine oxide, Blend - Coatings, Ester, Eth. natural alcohol, Eth. synthetic alcohol, Polysorbate, Sorbitan ester, Sultaine	Longa duração	*Shelf Life* sem variação
Alcohol, Alkyl Sulfonate, Amidoamine, Betaine, Break Fluid, Eth. Tallow amine, Eth. triestyryl phenol, Eth. coconut amine, Fatty acid, Glycol, Natural fatty alcohol	Acelerado	Menos de 2 produtos
Alkyl sulfate, Amine oxide, Blend - Coatings, Ester, Eth. natural alcohol, Eth. synthetic alcohol, Polysorbate, Propoxylated natural alcohol, Sorbitan ester, Sultaine	Acelerado	*Shelf Life* sem variação
Alkanolamine, Betaine, Eth. Tallow amine, Eth. rapeseed oil, Glycol, Natural fatty alcohol, Nonylphenol, Other propoxylate, Polysorbate	Acompanhamento	Menos de 2 produtos
Blend - Crop, Eth. Fatty acid, Eth. bisphenol, Eth. castor oil, Eth. triestyryl phenol, Glycol eter	Acompanhamento	*Shelf Life* sem variação

4.1.5 Síntese Geral — RF Sem Limites

Síntese

A versão sem limites deve ser entendida como uma versão de **cobertura máxima com interpretação graduada**. Ela é valiosa para mostrar ao cliente tudo o que foi possível calcular e para oferecer uma visão ampla dos ensaios que aparecem com maior frequência entre as famílias — especialmente **Água, %p**, **pH**, **Índice de acidez**, **Índice de hidroxila**, **Índice de saponificação** e variáveis de **cor**.

A leitura deve sempre diferenciar três grupos: (1) famílias com resultados mais convincentes, (2) famílias com resultados exploratórios por baixa amostra, e (3) famílias que nem sequer puderam ser calculadas por ausência de base mínima.

4.2 XGBoost — Versão Sem Limites

4.2.1 Cenário de Longa Duração

No cenário de longa duração, alguns resultados permaneceram tecnicamente bastante coerentes. A família **Other ethoxylate** mostrou um padrão consistente, com forte predominância de **Água, %p**, seguida por **RSN, Número de água, mL** e contribuição muito pequena de **pH 5% p/p, aquoso, 25ºC**. Como essa família possui sete produtos, o resultado pode ser considerado relativamente confiável, especialmente porque o peso não ficou totalmente colapsado em uma única variável. **Alkyl Ester** continuou apresentando um dos padrões mais interpretáveis do conjunto, com destaque para **Índice de saponificação**, **Índice de acidez**, **Água, %p** e **Cor Gardner**. A família **Blend - Crop** também apresentou leitura robusta, com dominância de **Água, %p**, mas ainda com contribuição relevante de **Índice de aminas totais**, **Cor Gardner**, **pH** e **Sólidos**.

Diversas famílias exigem interpretação muito cautelosa. Em **Glycol eter**, **Ethoxylated nonyl phenol**, **Blend - HPC**, **Blend - E&R** e **Phosphate ester**, o XGBoost concentrou toda a importância em uma única variável, produzindo Peso 1 = 1,000 e pesos nulos para as demais. A maioria dessas famílias possui apenas dois ou três produtos.

4.2.2 Cenário Acelerado

Algumas famílias se mantiveram interpretáveis e coerentes. **Other ethoxylate** continuou apresentando forte protagonismo de **Água, %p**, mas agora com participação também de **Índice de hidroxila**, **pH 5%** e **RSN**. **Blend - Crop** também se destacou,

com dominância de **Água, %p**, seguida de **Umidade**, **pH 1%** e **Índice de aminas totais**. **Alkyl Ester** novamente apareceu como uma das famílias mais consistentes, com **Índice de saponificação** e **Índice de acidez** como ensaios principais.

Por outro lado, **Alkanolamine**, **Alkyl aryl Sulfonate**, **Alkylether Sulfate**, **Blend - HPC**, **Blend - E&R**, **Ethoxylated nonyl phenol** e **Glycol eter** apresentaram peso integral ou praticamente integral em um único ensaio, frequentemente com apenas dois ou três produtos na família.

4.2.3 Cenário de Acompanhamento

A leitura ficou um pouco mais equilibrada em algumas famílias. **Ethoxylated natural alcohol** foi uma das famílias mais convincentes, apresentando distribuição relativamente razoável da importância entre **Índice de hidroxila**, **Índice de acidez**, **Cor Pt-Co, 60ºC**, **Água, %p** e **pH**, além de contar com onze produtos. **Ethoxylated synthetic alcohol** também mostrou um resultado interpretável, com **Água, %p**, **Índice de acidez** e **Índice de hidroxila** formando o núcleo principal do ranking. A família **Ethoxylated nonyl phenol** apresentou um padrão bifatorial, em que **Água, %p** e **Cor Pt-Co, 25ºC** praticamente dividiram a importância.

Em contrapartida, **Alcohol** (2 produtos), **Alkylether Sulfate** (3 produtos) e **Blend - Coatings** (3 produtos) apresentaram peso integral em um único ensaio. **Blend - E&R** apareceu na tabela, mas com todos os pesos iguais a zero.

4.2.4 Síntese Geral — XGBoost Sem Limites

Síntese

A versão sem limites com XGBoost mostrou que alguns ensaios aparecem de forma recorrente entre as primeiras posições, especialmente **Água, %p**, **Índice de acidez**, **Índice de hidroxila**, **Índice de saponificação**, **pH** e variáveis de **cor**.

Famílias com maior número de produtos e pesos mais distribuídos — como **Other ethoxylate**, **Alkyl Ester**, **Blend - Crop**, **EOPO copolymer**, **Ethoxylated natural alcohol**, **Ethoxylated synthetic alcohol** e **Ethoxylated nonyl phenol** — permitem uma leitura mais convincente. Já famílias pequenas com apenas dois ou três produtos, especialmente quando exibem Peso 1 = 1,000 e todos os demais pesos iguais a zero, devem ser tratadas como **exploratórias**.

Em síntese, a versão sem limites com XGBoost é especialmente valiosa quando o objetivo é mostrar ao cliente a **cobertura máxima do que foi possível calcular**, mas exige mais cautela interpretativa do que a versão com limites e, em certos casos, até mais cautela do que a versão sem limites com Random Forest,

pois o XGBoost tende a ser mais agressivo na concentração das importâncias.

Capítulo 5

Análise Sem Ensaios de Água

5.1 Motivação e Ensaios Excluídos

A análise descrita nos capítulos anteriores revelou que ensaios relacionados à água — em especial **Água, %p** — ocuparam consistentemente as primeiras posições no ranking de importância em diversas famílias e cenários. Esse resultado, embora quimicamente coerente, levantou uma questão metodológica relevante: *na ausência dos ensaios de água, quais outros parâmetros físico-químicos apresentam associação significativa com o Shelf Life?*

Para responder a essa pergunta, foi conduzida uma análise de sensibilidade na qual os cinco ensaios relacionados à água foram removidos antes do treinamento dos modelos. Todos os demais aspectos metodológicos — engenharia de variáveis temporais, estrutura dos modelos, regras de inclusão e algoritmos utilizados — foram mantidos exatamente como nas análises anteriores.

Os ensaios excluídos foram:

- `Água, %p`
- `Umidade, %p`
- `Umidade ou Material Volátil, %p`
- `Água+pesados, %p`
- `RSN, Número de água, mL`

Os resultados desta análise complementar são apresentados a seguir, nas versões com limites e sem limites, para Random Forest e XGBoost.

5.2 Resultados — Versão com Limites

5.2.1 Random Forest — Com Limites, Sem Ensaios de Água

Cenário de Longa Duração

Na versão com limites e sem ensaios de água, o cenário de longa duração retornou três famílias válidas. A exclusão dos ensaios de água provocou mudanças notáveis na composição dos rankings.

Em **Alkyl Ester**, o padrão de importância se manteve altamente coerente com a análise original: o **Índice de saponificação** continuou em primeiro lugar (peso 0,662), seguido pelo **Índice de acidez** (0,264) e **Cor Gardner, 25ºC** (0,074). O descritor dominante do índice de saponificação passou de `slope` para `delta_total`, indicando que a mudança acumulada ao longo do estudo se torna o sinal mais relevante quando a água não compete pela importância. Esse resultado confirma que a degradação química progressiva desta família — captada por índices de acidez e saponificação — é um sinal independente da água e suficientemente forte para liderar o ranking.

Em **Blend - Crop**, com a remoção de Água, %p, a **Cor Gardner, 25ºC** passou a ocupar o primeiro lugar (peso 0,613), seguida pelo **pH 1% p/p, aquoso, 25ºC** (0,387). O descritor dominante da cor foi `min_margin_norm`, sugerindo que a proximidade crítica da cor ao limite de especificação durante o estudo é o principal sinal associado ao *shelf life* desta família quando a água é abstraída.

Em **Other ethoxylate**, a exclusão da água deixou apenas o **Índice de hidroxila** como ensaio válido, com peso praticamente zero. Trata-se de um resultado esperado: essa família dependia fortemente da água como variável explicativa, e sem ela o modelo não encontrou sinal suficiente para discriminar o *shelf life* dentro dos critérios de inclusão.

Cenário Acelerado

No cenário acelerado, o padrão foi similar ao de longa duração, com três famílias retornando resultados válidos.

Em **Other ethoxylate**, na ausência da água, o **Índice de hidroxila** assumiu toda a importância (peso 1,000), com descritor dominante `min_margin_norm`. Esse resultado indica que a posição mínima de margem ao limite durante o estudo acelerado é o principal sinal de shelf life nessa família uma vez que a água é retirada da análise. Apesar do peso 1,000 indicar concentração total, a família possui 8 produtos — contexto em que esse resultado tem interpretabilidade razoável.

Em **Blend - Crop**, a **Cor Gardner, 25ºC** ficou em primeiro lugar (peso 0,580), com `min_margin_norm` como descritor dominante, seguida pelo **pH 1% p/p, aquoso, 25ºC** (0,420), com descritor `slope`. O resultado é fortemente consistente com a longa duração, confirmando que esses dois ensaios formam o núcleo explicativo da família

Blend – Crop quando a água não está disponível.

Em **Alkyl Ester**, o **Índice de acidez** liderou (peso 0,400, descritor `delta_total`), seguido pelo **Índice de saponificação** (0,369, descritor `abs_slope`) e **Cor Gardner, 25ºC** (0,231, descritor `abs_slope`). Comparando com a análise original sem a exclusão da água, a posição relativa de acidez e saponificação se inverteu no acelerado, mas ambos continuam sendo os ensaios dominantes.

Cenário de Acompanhamento

No cenário de acompanhamento, a remoção dos ensaios de água não reduziu o número de famílias válidas, e os rankings se tornaram ainda mais distribuídos.

Em **Ethoxylated natural alcohol**, o **Índice de hidroxila** permaneceu em primeiro lugar (peso 0,551, descritor `min_margin_norm`), seguido pelo **Índice de acidez** (0,365, descritor `slope`). O **pH 1% p/p** (0,046), o **Óxido de Eteno, ppm** (0,026) e a **Cor Pt-Co, 60ºC** (0,012) completaram o Top 5. Nota-se que, nessa família, a remoção da água não alterou substancialmente o ranking: hidroxila e acidez já eram dominantes na análise original.

Em **Ethoxylated synthetic alcohol**, o **Óxido de Eteno, ppm** ficou em primeiro (peso 0,406, descritor `min_margin_norm`), seguido pelo **Índice de hidroxila** (0,328, descritor `delta_total`) e pelo **Índice de acidez** (0,241, descritor `slope`). O **Ponto de névoa** (0,008) e o **pH** (0,006) completaram o ranking. A distribuição é muito próxima à observada na análise com água, confirmando que o Óxido de Eteno e o Índice de hidroxila são os sinais dominantes independentemente da presença da água.

Em **Ethoxylated nonyl phenol**, a **Cor Pt-Co, 25°C** liderou (peso 0,381, descritor `min_margin_norm`), seguida pelo **Índice de acidez** (0,272, descritor `delta_total`), pelo **Índice de hidroxila** (0,252, descritor `min_margin_norm`) e pelo **pH 1%** (0,095, descritor `abs_slope`). Na análise original (com água), a ordem era praticamente idêntica, o que indica que a Cor Pt-Co é o ensaio mais informativo desta família com ou sem a água.

Tabela 5.1: Ranking RF com limites, sem ensaios de água — todos os cenários.

Cenário	Família	Pr.	1º Ensaio	Peso	2º Ensaio	Peso
Longa duração	Alkyl Ester	9	Índ. saponificação	0,662	Índ. acidez	0,264
	Blend – Crop	12	Cor Gardner, 25ºC	0,613	pH 1% p/p	0,387
	Other ethoxylate	7	Índ. hidroxila	0	–	–
Acelerado	Other ethoxylate	8	Índ. hidroxila	1,000	–	–
	Blend – Crop	13	Cor Gardner, 25ºC	0,580	pH 1% p/p	0,420
	Alkyl Ester	9	Índ. acidez	0,400	Índ. saponificação	0,369
Acompanhamento	Eth. natural alcohol	11	Índ. hidroxila	0,551	Índ. acidez	0,365
	Eth. synthetic alcohol	5	Óxido de Eteno	0,406	Índ. hidroxila	0,328
	Eth. nonyl phenol	5	Cor Pt-Co, 25°C	0,381	Índ. acidez	0,272

Síntese — RF com Limites Sem Água

Síntese

A análise RF com limites sem ensaios de água revelou que o **Índice de saponificação** e o **Índice de acidez** mantêm protagonismo em **Alkyl Ester** em todos os cenários, confirmando que degradação química progressiva é o mecanismo dominante dessa família independentemente da água. Para **Blend – Crop**, a **Cor Gardner** e o **pH** emergem consistentemente como os principais ensaios substitutos. Nas famílias de álcoois etoxilados (acompanhamento), os rankings permaneceram praticamente inalterados, sugerindo que a água tinha contribuição secundária nesses casos. O principal impacto da exclusão da água foi em **Other ethoxylate**, onde o modelo ficou com pouquíssimos ensaios válidos em longa duração, enquanto no acelerado o Índice de hidroxila assumiu toda a importância.

5.2.2 XGBoost — Com Limites, Sem Ensaios de Água

Cenário de Longa Duração

O XGBoost com limites e sem água produziu resultados tecnicamente coerentes nas três famílias disponíveis.

Em **Alkyl Ester**, o **Índice de saponificação** concentrou a maior parte da importância (peso 0,833, descritor `slope`), seguido pelo **Índice de acidez** (0,151, descritor `delta_total`) e **Cor Gardner, 25ºC** (0,015, descritor `abs_slope`). O XGBoost confirmou com ainda maior concentração o que o RF já indicava: a saponificação é o ensaio crítico de longa duração para esta família.

Em **Blend - Crop**, a ordem se inverteu ligeiramente em relação ao RF: o **pH 1% p/p, aquoso, 25ºC** ficou em primeiro lugar (peso 0,536, descritor `slope`), enquanto a **Cor Gardner, 25ºC** ficou em segundo (0,464, descritor `min_margin_norm`). Os dois ensaios continuam sendo os únicos válidos na família após os filtros, e sua relativa paridade nos pesos indica que nenhum dos dois domina claramente.

Em **Other ethoxylate**, o resultado foi idêntico ao RF: apenas o **Índice de hidroxila** restou após os filtros, com peso zero.

Cenário Acelerado

No cenário acelerado, o XGBoost apresentou um padrão muito próximo ao observado no RF.

Em **Other ethoxylate**, o **Índice de hidroxila** novamente concentrou toda a importância (peso 1,000), agora com descritor `delta_total` — diferente do RF, que identificou `min_margin_norm`. A mudança de descritor dominante sugere que, para o XGBoost, a variação acumulada ao longo do estudo acelerado foi o sinal mais explorado, enquanto o RF priorizou a menor margem ao limite.

Em **Alkyl Ester**, o **Índice de saponificação** liderou com clareza (peso 0,690, descritor `min_margin_norm`), seguido pelo **Índice de acidez** (0,195, descritor `delta_total`) e **Cor Gardner, 25ºC** (0,116, descritor `min_margin_norm`).

Em **Blend - Crop**, o **pH 1% p/p, aquoso, 25ºC** ficou em primeiro lugar (peso 0,547, descritor `delta_total`), seguido pela **Cor Gardner, 25ºC** (0,453, descritor `min_margin_norm`). Esse padrão é consistente com a longa duração e com o RF.

Cenário de Acompanhamento

Os resultados do cenário de acompanhamento foram ligeiramente diferentes entre RF e XGBoost.

Em **Ethoxylated nonyl phenol**, o XGBoost concentrou toda a importância na **Cor Pt-Co, 25°C** (peso 1,000, descritor `delta_total`). Esse padrão de concentração

extrema é característico do XGBoost em famílias pequenas (5 produtos) e deve ser lido com cautela, ainda que o ensaio indicado seja o mesmo que o RF apontou em primeiro lugar.

Em **Ethoxylated synthetic alcohol**, os resultados foram mais distribuídos: o **Índice de acidez** ficou em primeiro (peso 0,523, descritor `slope`), seguido pelo **Índice de hidroxila** (0,437, descritor `abs_slope`) e pelo **Óxido de Eteno** (0,026). A ordem entre acidez e óxido de eteno se inverteu em relação ao RF, mas ambos os ensaios permanecem entre os mais relevantes.

Em **Ethoxylated natural alcohol**, o **Índice de hidroxila** ficou em primeiro (peso 0,404, descritor `min_margin_norm`), seguido pelo **Índice de acidez** (0,292, descritor `slope`) e pela **Cor Pt-Co, 60ºC** (0,263, descritor `delta_total`). Comparando com o RF, a cor emergiu com peso maior no XGBoost, enquanto o pH recuou.

Tabela 5.2: Ranking XGBoost com limites, sem ensaios de água — todos os cenários.

Cenário	Família	Pr.	1º Ensaio	Peso	2º Ensaio	Peso
Longa duração	Alkyl Ester	9	Índ. saponificação	0,833	Índ. acidez	0,151
	Blend – Crop	12	pH 1% p/p	0,536	Cor Gardner, 25ºC	0,464
	Other ethoxylate	7	Índ. hidroxila	0	–	–
Acelerado	Other ethoxylate	8	Índ. hidroxila	1,000	–	–
	Alkyl Ester	9	Índ. saponificação	0,690	Índ. acidez	0,195
	Blend – Crop	13	pH 1% p/p	0,547	Cor Gardner, 25ºC	0,453
Acompanhamento	Eth. nonyl phenol	5	Cor Pt-Co, 25°C	1,000	–	–
	Eth. synthetic alcohol	5	Índ. acidez	0,523	Índ. hidroxila	0,437
	Eth. natural alcohol	11	Índ. hidroxila	0,404	Índ. acidez	0,292

Síntese — XGBoost com Limites Sem Água

Síntese

O XGBoost com limites sem água confirma as principais conclusões do RF: **Índice de saponificação** e **Índice de acidez** são os ensaios mais importantes para **Alkyl Ester**; **Cor Gardner** e **pH** lideram em **Blend – Crop**; e os álcoois etoxilados mantêm seus rankings praticamente inalterados. O XGBoost tende a concentrar mais fortemente em poucos ensaios, mas os ensaios identificados são consistentes com o RF na grande maioria dos casos.

5.3 Resultados — Versão Sem Limites

Atenção — Interpretação dos Resultados

Na versão sem limites sem água, a interpretação exige o mesmo cuidado já descrito no Capítulo 4: famílias com apenas dois ou três produtos e Peso 1 = 1,000 devem ser tratadas como pistas exploratórias, não como conclusões robustas.

5.3.1 Random Forest — Sem Limites, Sem Ensaios de Água

Cenário de Longa Duração

A versão sem limites ampliou o número de famílias analisadas para 12 no cenário de longa duração.

Algumas famílias apresentaram resultados tecnicamente convincentes. Em **Alkyl Ester** (9 produtos), o **Índice de saponificação** liderou (peso 0,647), seguido pelo **Índice de acidez** (0,257) e **Cor Gardner, 25ºC** (0,089). O padrão é coerente e consistente com a versão com limites.

Em **Blend - Crop** (12 produtos), a distribuição foi mais dispersa do que na versão com limites: **Sólidos, %p** liderou (0,307), seguido por **pH, tal qual, 25°C** (0,203), **Índice de aminas totais, IAT** (0,107), **Ácido fosfórico livre, %p** (0,100) e **Cor Gardner, 25ºC** (0,084). A ausência de água e o maior conjunto de ensaios disponíveis permitiu que a análise captasse um perfil mais multifatorial desta família.

Em **Other ethoxylate** (7 produtos), sem a água, o **Índice de hidroxila** ficou em primeiro (peso 0,650) e o **pH 5% p/p, aquoso, 25ºC** em segundo (0,350). Esse resultado é mais informativo do que a versão com limites (onde apenas 1 ensaio era válido), e aponta para o pH e o índice de hidroxila como os ensaios substitutos.

Em **EOPO copolymer** (4 produtos), o **pH 1% p/p, aquoso, 25ºC** concentrou 66,2% da importância, com o **pH 2,5% aquoso** completando 33,8%.

Em **Alkylether Sulfate** (4 produtos), um perfil totalmente distinto emergiu: **Insulfatados, %p** (0,416), **Cloreto de sódio, %p** (0,293), **Sulfato de sódio, %p** (0,184), **Insulfatados via GC** (0,044) e **Dioxana, ppm** (0,036). Esses ensaios são específicos da classe de surfactantes aniônicos e coerentes com os mecanismos de degradação esperados.

Em **Polyethylene glycol** (4 produtos), o ranking foi distribuído: **Índice de acidez** (0,281), **pH 5%** (0,268), **Índice de hidroxila** (0,213), **Cor Pt-Co 25ºC** (0,170) e **Viscosidade** (0,037).

Os demais resultados (Phosphate ester, Alkyl aryl Sulfonate, Glycol eter, Ethoxylated nonyl phenol) devem ser tratados com cautela — famílias com 2 a 3 produtos. Blend – E&R e Blend – HPC não geraram rankings úteis (todos os pesos iguais a zero).

Cenário Acelerado

No acelerado sem limites, a análise expandiu para 12 famílias.

Em **Other ethoxylate** (8 produtos), o **Índice de hidroxila** concentrou 90,1% da importância, com o **pH 5%** contribuindo com 9,9%. A forte dominância do índice de hidroxila no acelerado, já observada na versão com limites, se repete aqui.

Em **EOPO copolymer** (4 produtos) e **Phosphate ester** (4 produtos), os ensaios de pH e ponto de névoa lideraram, respectivamente. Em **Alkylether Sulfate**, o perfil de insulfatados, cloreto de sódio e sulfato de sódio se repetiu, desta vez liderado por **Insulfatados, %p** (0,478).

Em **Blend - Crop** (13 produtos), o ranking foi distribuído entre **pH 1% p/p** (0,223), **Sólidos** (0,178), **pH tal qual** (0,177), **IAT** (0,160) e **Ácido fosfórico livre** (0,102) — perfil bastante similar ao da longa duração.

Cenário de Acompanhamento

No acompanhamento, a versão sem limites produziu 6 famílias, com resultados de qualidade variada.

Em **Ethoxylated natural alcohol** (11 produtos), o **Índice de hidroxila** liderou (0,470), seguido pelo **Índice de acidez** (0,269), **Peróxidos** (0,077), **pH 1%** (0,045) e **pH 10%** (0,028). O aparecimento de **Peróxidos** como terceiro ensaio mais importante é notável — na análise com água ele não aparecia entre os primeiros cinco, sugerindo que a exclusão da água permitiu capturar um sinal adicional de oxidação.

Em **Ethoxylated synthetic alcohol** (5 produtos), o **Óxido de Eteno, ppm** ficou em primeiro (0,453), seguido pelo **Índice de hidroxila** (0,304) e **Índice de acidez** (0,221). O padrão é consistente com a versão com limites.

Em **Ethoxylated nonyl phenol** (5 produtos), o resultado foi distribuído: **Cor**

Pt-Co, 25°C (0,336), **Índice de acidez** (0,270), **Índice de hidroxila** (0,268), **pH 1%** (0,126). Sem a presença da água no ranking, a cor e a acidez se destacam com pesos próximos.

Em **Alkylether Sulfate** (3 produtos), o perfil de **Dioxana** (0,305), **Sulfato de sódio** (0,250), **Insulfatados via GC** (0,235) e **Cloreto de sódio** (0,210) emergiu.

Em **Ester** (3 produtos) e **Alcohol** (2 produtos), os resultados devem ser tratados como exploratórios.

Tabela 5.3: Ranking RF sem limites, sem ensaios de água — famílias com maior confiabilidade ($\geq$ 4 produtos).

Cenário	Família	Pr.	1º Ensaio	Peso	2º Ensaio	Peso
Longa duração	Alkyl Ester	9	Índ. saponificação	0,647	Índ. acidez	0,257
	Blend – Crop	12	Sólidos, %p	0,307	pH tal qual	0,203
	Other ethoxylate	7	Índ. hidroxila	0,650	pH 5% p/p	0,350
	Alkylether Sulfate	4	Insulfatados, %p	0,416	Cloreto de sódio	0,293
	Polyethylene glycol	4	Índ. acidez	0,281	pH 5% p/p	0,268
Acelerado	Other ethoxylate	8	Índ. hidroxila	0,901	pH 5% p/p	0,099
	Alkylether Sulfate	4	Insulfatados, %p	0,478	Cloreto de sódio	0,299
	Polyethylene glycol	4	pH 5% p/p	0,449	Índ. acidez	0,297
	EOPO copolymer	4	pH 1% p/p	0,666	pH 2,5%	0,334
	Blend – Crop	13	pH 1% p/p	0,223	Sólidos, %p	0,178
Acompanhamento	Eth. natural alcohol	11	Índ. hidroxila	0,470	Índ. acidez	0,269
	Eth. synthetic alcohol	5	Óxido de Eteno	0,453	Índ. hidroxila	0,304
	Eth. nonyl phenol	5	Cor Pt-Co, 25°C	0,336	Índ. acidez	0,270

Síntese — RF Sem Limites Sem Água

Síntese

A versão RF sem limites sem água revelou ensaios antes obscurecidos pela dominância da água. Os achados mais relevantes incluem: o surgimento de **pH**, **Sólidos** e **IAT** como ensaios centrais em **Blend – Crop**; a manutenção do perfil de **Insulfatados**, **Cloreto de sódio** e **Sulfato de sódio** em **Alkylether Sulfate**; o aparecimento de **Peróxidos** em **Ethoxylated natural alcohol**; e a confirmação do **Índice de hidroxila** e **pH** como principais substitutos da água em **Other ethoxylate**. Para **Alkyl Ester** e álcoois etoxilados, os rankings permaneceram estáveis, mostrando independência em relação à presença dos ensaios de água.

5.3.2 XGBoost — Sem Limites, Sem Ensaios de Água

Cenário de Longa Duração

No cenário de longa duração, o XGBoost sem limites e sem água apresentou resultados com concentração acentuada em algumas famílias.

Em **Alkyl Ester** (9 produtos), o padrão foi coerente: **Índice de saponificação** (0,733), **Índice de acidez** (0,233) e **Cor Gardner, 25ºC** (0,030). Em **Other ethoxylate** (7 produtos), o XGBoost dividiu a importância quase igualmente entre **pH 5% p/p** (0,506) e **Índice de hidroxila** (0,494) — resultado diferente do RF, que priorizou mais fortemente o índice de hidroxila.

Em **Blend - Crop** (12 produtos), o **Sólidos, %p** concentrou 41,8%, seguido pelo **IAT** (21,8%), **Cor Gardner** (21,8%), **pH 1%** (11,4%) e **Densidade** (3,2%). A distribuição é mais concentrada do que no RF, mas os ensaios são similares.

Famílias com 2–3 produtos (Alkyl aryl Sulfonate, Alkylether Sulfate, Ethoxylated nonyl phenol, Glycol eter, Phosphate ester) apresentaram Peso 1 = 1,000 e devem ser interpretadas com cautela.

Cenário Acelerado

Em **Other ethoxylate** (8 produtos), o XGBoost apresentou **Índice de hidroxila** em primeiro lugar (0,794) e **pH 5%** em segundo (0,206) — padrão idêntico ao RF, mas com pesos ligeiramente mais concentrados.

Em **Alkyl Ester** (9 produtos), o **Índice de saponificação** liderou (0,633), seguido pelo **Índice de acidez** (0,175), **Cor Gardner, 60ºC** (0,119) e **Cor Gardner, 25ºC** (0,072).

Em **Blend - Crop** (13 produtos), o **pH 1% p/p** ficou em primeiro (0,353), com **IAT** (0,311), **Densidade** (0,195) e **Cor Gardner** (0,107) completando o ranking.

Cenário de Acompanhamento

Em **Ethoxylated natural alcohol** (11 produtos), o ranking incluiu **Índice de hidroxila** (0,443), **Cor Pt-Co, 60ºC** (0,280), **Índice de acidez** (0,240) e **pH 1%** (0,037). Nota-se que a **Cor Pt-Co** teve peso maior no XGBoost do que no RF nessa família.

Em **Ethoxylated synthetic alcohol** (5 produtos), a distribuição foi equilibrada entre **Índice de hidroxila** (0,500) e **Índice de acidez** (0,461), com **Óxido de Eteno** em terceiro (0,027). Comparando com o RF, o XGBoost inverteu a posição relativa de hidroxila e acidez.

Em **Ethoxylated nonyl phenol** (5 produtos), novamente o XGBoost concentrou toda a importância na **Cor Pt-Co, 25°C** (1,000) — resultado consistente com a versão com limites.

Tabela 5.4: Ranking XGBoost sem limites, sem ensaios de água — famílias com maior confiabilidade ($\geq$ 4 produtos).

Cenário	Família	Pr.	1º Ensaio	Peso	2º Ensaio	Peso
Longa duração	Alkyl Ester	9	Índ. saponificação	0,733	Índ. acidez	0,233
	Blend – Crop	12	Sólidos, %p	0,418	IAT	0,218
	Other ethoxylate	7	pH 5% p/p	0,506	Índ. hidroxila	0,494
	Alkylether Sulfate	4	Cloreto de sódio	1,000	–	–
	EOPO copolymer	4	pH 1% p/p	0,945	pH 2,5%	0,055
Acelerado	Other ethoxylate	8	Índ. hidroxila	0,794	pH 5% p/p	0,206
	Alkyl Ester	9	Índ. saponificação	0,633	Índ. acidez	0,175
	Blend – Crop	13	pH 1% p/p	0,353	IAT	0,311
	Alkylether Sulfate	4	Cloreto de sódio	0,992	Insulfatados	0,008
	EOPO copolymer	4	pH 1% p/p	0,956	pH 2,5%	0,044
Acompanhamento	Eth. natural alcohol	11	Índ. hidroxila	0,443	Cor Pt-Co, 60ºC	0,280
	Eth. synthetic alcohol	5	Índ. hidroxila	0,500	Índ. acidez	0,461
	Eth. nonyl phenol	5	Cor Pt-Co, 25°C	1,000	–	–

Síntese — XGBoost Sem Limites Sem Água

Síntese

O XGBoost sem limites sem água confirmou os principais achados do RF na mesma configuração, com a diferença esperada de maior concentração de importância em poucos ensaios. Para as famílias com maior número de produtos (**Alkyl Ester**, **Blend – Crop**, **Other ethoxylate**, **Ethoxylated natural alcohol**), os resultados foram consistentes entre os dois algoritmos. A maior discrepância foi observada em **EOPO copolymer** e **Alkylether Sulfate**, onde o XGBoost tendeu a colapsar a importância em um único ensaio mesmo com 4 produtos.

5.4 Impacto da Exclusão da Água: Comparativo com a Análise Principal

A comparação entre os rankings da análise original (com todos os ensaios) e a análise sem água permite identificar quais famílias dependiam fortemente da água e quais apresentavam sinais independentes.

Tabela 5.5: Impacto da exclusão dos ensaios de água por família — versão RF com limites.

Cenário	Família	1º orig. (com água)	1º (excl. água)	Impacto da exclusão
Longa duração	Other ethoxylate	Água, %p	Índ. hidroxila (peso ≈0)	Alto: ranking praticamente vazio
	Alkyl Ester	Índ. saponificação	Índ. saponificação	Baixo: mesmo ensaio líder
	Blend – Crop	Água, %p	Cor Gardner	Médio: Cor Gardner emerge
Acelerado	Other ethoxylate	Água, %p	Índ. hidroxila (1,000)	Alto: hidroxila assume posição
	Alkyl Ester	Índ. acidez	Índ. acidez	Baixo: mesmo ensaio líder
	Blend – Crop	Água, %p	Cor Gardner	Médio: Cor Gardner emerge
Acompanhamento	Eth. natural alcohol	Índ. hidroxila	Índ. hidroxila	Baixo: sem alteração
	Eth. synthetic alcohol	Óxido de Eteno	Óxido de Eteno	Baixo: sem alteração
	Eth. nonyl phenol	Cor Pt-Co	Cor Pt-Co	Baixo: sem alteração

A análise da Tabela 5.5 permite classificar as famílias em três grupos:

1. **Alta dependência da água** — **Other ethoxylate** (longa duração): a remoção da água deixou o modelo praticamente sem sinal útil em longa duração, mas no acelerado o índice de hidroxila emergiu como substituto relevante.

2. **Dependência parcial da água** — **Blend – Crop**: a água era o ensaio líder na análise original, mas a exclusão revelou que **Cor Gardner** e **pH** (ou Sólidos e IAT na versão sem limites) carregam sinal independente substancial.

3. **Independência da água** — **Alkyl Ester** e as três famílias de álcoois etoxilados no acompanhamento: os rankings foram praticamente idênticos com e sem a exclusão da água, demonstrando que os ensaios líderes nessas famílias possuem poder explicativo autônomo.

5.5 Síntese Geral — Análise Sem Ensaios de Água

Síntese

Os principais achados desta análise complementar são:

1. Robustez confirmada para Alkyl Ester: O *Índice de saponificação* e o *Índice de acidez* mantêm protagonismo em todos os cenários, tanto na análise com água quanto sem ela. Esse resultado consolida a hipótese de que a degradação química progressiva — não relacionada ao teor de umidade — é o mecanismo dominante de limitação do *shelf life* nesta família.

2. Ensaios substitutos para Other ethoxylate: Quando os ensaios de água são excluídos, o *Índice de hidroxila* e o *pH 5% p/p* emergem como os principais sinais substitutos. No cenário acelerado, o índice de hidroxila assume posição de liderança com peso relevante (0,794–1,000 entre RF e XGBoost), sugerindo que parte do poder preditivo da água nessa família pode ser recuperado por esses ensaios.

3. Blend - Crop revela estrutura multifatorial: A exclusão da água desloca o primeiro ensaio para *Cor Gardner* (versão com limites) ou para *Sólidos/pH* (versão sem limites). A família não dependia exclusivamente da água e possui múltiplos eixos explicativos.

4. Álcoois etoxilados são independentes da água: Para *Ethoxylated natural alcohol*, *Ethoxylated synthetic alcohol* e *Ethoxylated nonyl phenol*, os rankings foram praticamente inalterados, confirmando que os ensaios identificados como importantes são de fato os fatores primários do *shelf life* nessas famílias.

5. Novas perspectivas para monitoramento: O aparecimento de *Peróxidos* no ranking de *Ethoxylated natural alcohol* e de perfis específicos (*Insulfatados*, *Dioxana*, *Cloreto de sódio*) em *Alkylether Sulfate* indica que a análise sem água pode revelar mecanismos de degradação complementares não visíveis quando a umidade domina o ranking.

Capítulo 6

Conclusão

6.1 Achados Transversais

Em todos os cenários e em ambas as versões analisadas (com e sem limites), alguns ensaios se mostraram consistentemente relevantes para a explicação do *Shelf Life*:

- **Água, %p** — ensaio mais frequentemente dominante, aparecendo como fator principal em múltiplas famílias e cenários.
- **Índice de acidez** e **Índice de saponificação** — especialmente relevantes para **Alkyl Ester**, com forte indicação de vínculo à degradação química progressiva.
- **Índice de hidroxila** — recorrente em famílias de álcoois etoxilados, frequentemente associado à proximidade crítica do limite de especificação.
- **Cor Gardner** e **Cor Pt-Co** — ensaios de cor mostraram relevância especialmente em **Blend - Crop** e **Ethoxylated nonyl phenol**.
- **pH** — aparece como variável secundária ou complementar em diversas famílias.

6.2 Padrão dos Descritores Temporais

Os resultados mostraram que a importância dos ensaios não decorreu apenas da magnitude da variação ao longo do tempo, mas também de dois outros tipos de sinal:

- **Posição inicial em relação ao limite** (`margin0_norm`) — especialmente relevante em **Other ethoxylate** no cenário acelerado com RF e no cenário de longa duração com XGBoost.
- **Menor margem observada ao longo do estudo** (`min_margin_norm`) — importante para **Cor Gardner** em **Blend - Crop** e para **Índice de saponificação** em **Alkyl Ester** no acelerado com XGBoost.

- **Mudança acumulada** (`delta_total`) e **tendência temporal** (`slope`) — frequentemente dominantes em famílias com trajetória química progressiva.

6.3 Comparação entre Modelos e Versões

Tabela 6.1: Resumo comparativo entre modelos e versões.

Aspecto	RF c/ Limites	XGBoost c/ Limites	RF s/ Limites	XGBoost s/ Limites
Cobertura de famílias	Menor	Menor	Máxima	Máxima
Robustez geral	Alta	Alta	Variável	Variável
Concentração de pesos	Distribuída	Concentrada	Variável	Muito concentrada
Exibe descritor dominante	Sim	Sim	Não	Não
Uso recomendado	Conclusões	Conclusões	Exploração	Exploração

6.4 Recomendações

1. **Usar a versão com limites como base principal** para conclusões e comunicações técnicas ao cliente.
2. **Usar a versão sem limites como complemento exploratório**, apresentando-a com linguagem prudente e destacando o grau de robustez de cada família.
3. **Priorizar famílias com maior número de produtos** e com pesos menos extremos ao tomar decisões baseadas nos rankings.
4. **Não interpretar Peso 1 = 1,000 como exclusividade real do ensaio** em famílias com 2–3 produtos; esses casos refletem limitações amostrais e não necessariamente dominância química.
5. **Explorar os descritores dominantes** (especialmente `slope`, `delta_total` e `min_margin_norm`) para entender *como* cada ensaio se relaciona com o *Shelf Life*, e não apenas *qual* ensaio é mais importante.